Análisis de modelo predictivo

Eduardo Alvarado Gómez - A01251534

9/18/2022

Para este proyecto, se utilizaron los datos acerca de los Salarios contra la Experiencia en años. Este set de datos permitió utilizar un modelo de regresión lineal, ya que, como se puede ver en la gráfica, su comportamiento se acerca a uno lineal.

En este documento se incluye un modelo de Regresión lineal implementado y creado sin librerías integradas, y otro que muestra la implementación y adaptación de librerías que permite el cálculo de la regresión.

Para armar el modelo, se utilizó una estructura basada en funciones, que facilitan los cálculos en nuestro modelo de forma iterativa, siguiendo la estructura simple de la regresión, actualizando los pesos de nuestras variables hasta conseguir el mejor ajuste.

Aunque la Regresión lineal es un modelo bastante simple, se obtuvieron buenos resultados ya que se trata del mejor para este set de datos. Tales resultados se muestran al final del documento, así como la comparación de ambos modelos y sus respectivos análisis.

In [1]:
```
import numpy as np             # Librerías
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn import preprocessing, svm
from sklearn.model_selection import train_test_split

from sklearn.linear_model import LinearRegression  # Paquete Regresión Linear
```

In [2]:
```
# Modelo from scratch Regresión Lineal
```

In [3]:
```
class LinearR() :

    def __init__( self, learn_r, itera ) :

        self.learn_r = learn_r

        self.itera = itera
        return None


    def fit( self, X, Y ) :     # Model training

        self.m, self.n = X.shape



        self.W = np.zeros( self.n )  # Inicialización variables pesos
                                     # y = w*x + b
        self.b = 0

        self.X = X

        self.Y = Y



        for i in range( self.itera ) :    # Gradiente descendente

            self.update_w()

        return self



    def update_w( self ):       # Ajuste pesos: gradiente descendente

        Y_pred = self.predict( self.X )


        dW = - ( 2 * ( self.X.T ).dot( self.Y - Y_pred ) ) / self.m    # Cálcu
lo gradiente

        db = - 2 * np.sum( self.Y - Y_pred ) / self.m


        self.W = self.W - self.learn_r * dW     # Ajuste pesos

        self.b = self.b - self.learn_r * db

        return self



    def predict( self, X ) :     # Función H
```

```
        return X.dot(self.W) + self.b
```

In [4]:
```
df = pd.read_csv( "Salaries.csv" )    # Lectura datos

X = df.iloc[:,:-1].values

Y = df.iloc[:,1].values


X_train, X_test, Y_train, Y_test = train_test_split(    # Train & test set
X, Y, test_size = 0.25, random_state = 0 )

plt.scatter( X_train, Y_train, color = 'blue' )



model = LinearR( learn_r = 0.01,itera = 1000 )    # Training
model.fit(X_train,Y_train)

Y_pred = model.predict(X_test)   # Predicción
```

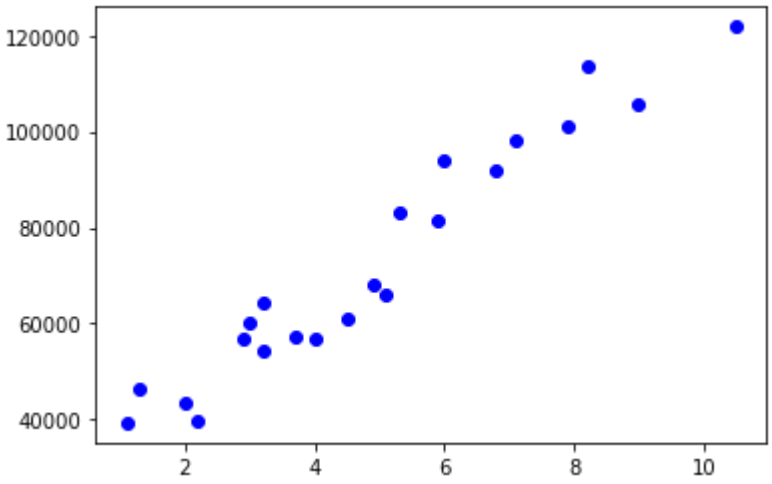

In [5]:
```
print( "Predicción ", np.round( Y_pred[:3], 2 ) )  # Resultados

print( "Reales ", Y_test[:3] )

print( "W ", round( model.W[0], 2 ) )

print( "b ", round( model.b, 2 ) )
```

```
Predicción  [ 40726.6  123893.62  65298.68]
Reales  [ 37731 122391  57081]
W  9450.8
b  26550.41
```

In [6]:
```
plt.scatter( X_test, Y_test, color = 'red' )   # Figuras de visualización

plt.plot( X_test, Y_pred, color = 'yellow' )

plt.title( 'Salario vs Experiencia' )

plt.xlabel( 'Experiencia(años)' )

plt.ylabel( 'Salario' )

plt.show()
```

In [7]:
```
# Modelo paquete Regresión Lineal
```

In [8]:
```
df2 = pd.read_csv('Salaries.csv')
df_bi = df2[['YearsExperience', 'Salary']]

df_bi.columns = ['Years', 'Sal']
df_bi.head()
```

Out[8]:

	Years	Sal
0	1.1	39343
1	1.3	46205
2	1.5	37731
3	2.0	43525
4	2.2	39891

In [9]:
```
sns.lmplot(x ="Years", y ="Sal", data = df_bi, order = 2, ci = None)    # Visualización datos
```

Out[9]: <seaborn.axisgrid.FacetGrid at 0x2183d46cd90>

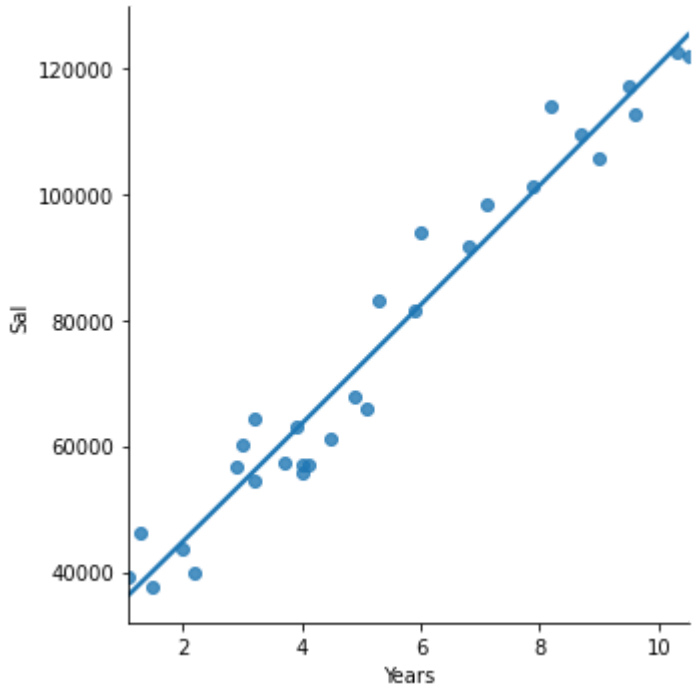

In [10]:
```
X = np.array(df_bi['Years']).reshape(-1, 1)
y = np.array(df_bi['Sal']).reshape(-1, 1)

X_train2, X_test2, y_train2, y_test2 = train_test_split(X, y, test_size = 0.25
) # Train y Test separación

model2 = LinearRegression()  # Llamamos a la librería

model2.fit(X_train2, y_train2)  # Train


print(model2.score(X_test2, y_test2))
```

```
0.9685312453017993
```

In [11]:
```
y_pred2 = model2.predict(X_test2)     # Predicción
print(model2.score(X_test2, y_test2)) # Score

plt.scatter(X_test2, y_test2, color ='b')
plt.plot(X_test2, y_pred2, color ='k')

plt.show()  # Visualización LR
```

```
0.9685312453017993
```

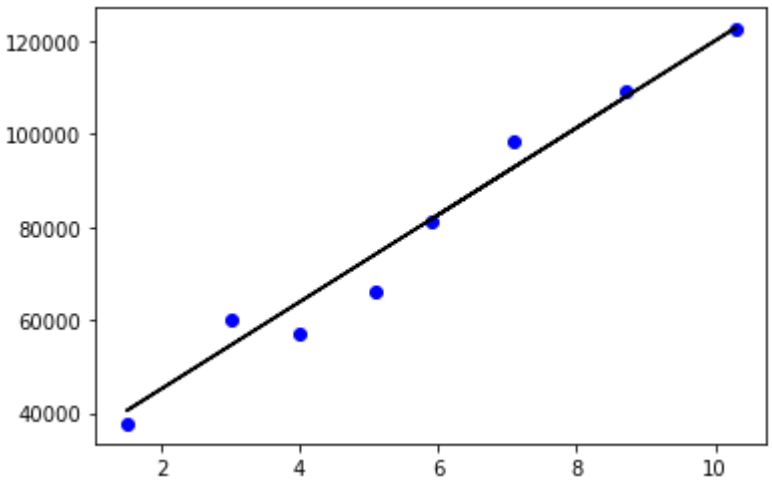

In [12]:
```
# Análisis y comparación modelos
```

In [13]:
```
from sklearn.metrics import mean_absolute_error,mean_squared_error,r2_score

# Modelo from scratch
mae = mean_absolute_error(y_true=Y_test,y_pred=Y_pred)
mse = mean_squared_error(y_true=Y_test,y_pred=Y_pred)
rmse = mean_squared_error(y_true=Y_test,y_pred=Y_pred,squared=False)
r2 = r2_score(y_true=Y_test,y_pred=Y_pred)

print("MAE:",mae)
print("MSE:",mse)
print("RMSE:",rmse)
print("R2:",r2)
```

```
MAE: 3425.468800564794
MSE: 21807636.097934574
RMSE: 4669.864676619075
R2: 0.9785123298086768
```

In [14]:
```
# Modelo librería
mae = mean_absolute_error(y_true=y_test2,y_pred=y_pred2)
mse = mean_squared_error(y_true=y_test2,y_pred=y_pred2)
rmse = mean_squared_error(y_true=y_test2,y_pred=y_pred2,squared=False)
r2 = r2_score(y_true=y_test2,y_pred=y_pred2)

print("MAE:",mae)
print("MSE:",mse)
print("RMSE:",rmse)
print("R2:",r2)
```

```
MAE: 3902.5781344374855
MSE: 23202059.514357246
RMSE: 4816.851618470019
R2: 0.9685312453017993
```

Al utilizar regresión lineal en ambos casos, nuestro análisis de errores resultó muy parecidos para los dos modelos. Con la visualización de los datos, al inicio del programa, se puede observar que se comportan de manera bastante lineal, Esto, aparte de suponer que nuestro modelo de regresión lineal será bien ajustado, nos indica que el grado de varianza debe ser bajo.

También, al ver los valores de MAE y RMSE, se puede concluir que, para el segundo modelo, probablemente se tenga menor varianza que para el primero, ya que el primero tiene un MAE menor, pero un RMSE casi igual al del segundo. La diferencia mayor entre estos valores indica una mayor varianza.

Al hablar del sesgo de nuestro modelo, resulta tener un nivel muy bajo. Esto es indicado por el R2, que nos dice que nuestro modelo tiene un buen ajuste. El bajo nivel del sesgo se debe al comportamiento lineal que presentan los datos, permitiendo un buen ajuste de nuestro modelo. El MAE que se presenta es bajo y nuestro R2 es alto, por lo que el sesgo es de un nivel bajo.

Al trabajar con una base de datos reducida y que presentó un comportamiento bastante lineal, el fitt o ajuste de nuestro modelo no fue un problema. Aún así, se podrían presentar problemas de underfitt si se utiliza nuestro modelo con más datos de prueba, al haber sido entrenado con muy pocos datos.

Se utilizó train-test-split, con un 25% de testing para evitar el underfitt. Inicialmente, se utilizó un testing de 1/3 de los datos, pero se obtuvieron mejores resultados con el presentado finalmente.